Projet Errol - Catégorisation des mails en HAM et SPAM

Cours Ingénierie des langues

Projet, 1ère phase

Martial Goehry

Université Paris 8, LIASD
Licence d'informatique

31 juillet 2024

Plan

Objectif

L'objectif est d'extraire des données d'e-mails pour déterminer s'ils sont des courriers légitimes ou de sollicitations indésirées.

- langue concernée : Anglais
- type de corpus : corpus monolingue écrit
- type de données : e-mail

Présentation de l'insfrastructure

Les traitements sont basés sur un ensemble de d'instruction écrites en Python.
L'infrastructure de données utilise 1 base NoSQL (mongoDB) et 2 bases SQL (Postgres et SQLite).
Les moteurs et services sont conteneurisés pour limiter l'impact sur la machine hôtes.
L'initialisation des schémas des bases de données est gérée directement par le programme Python.

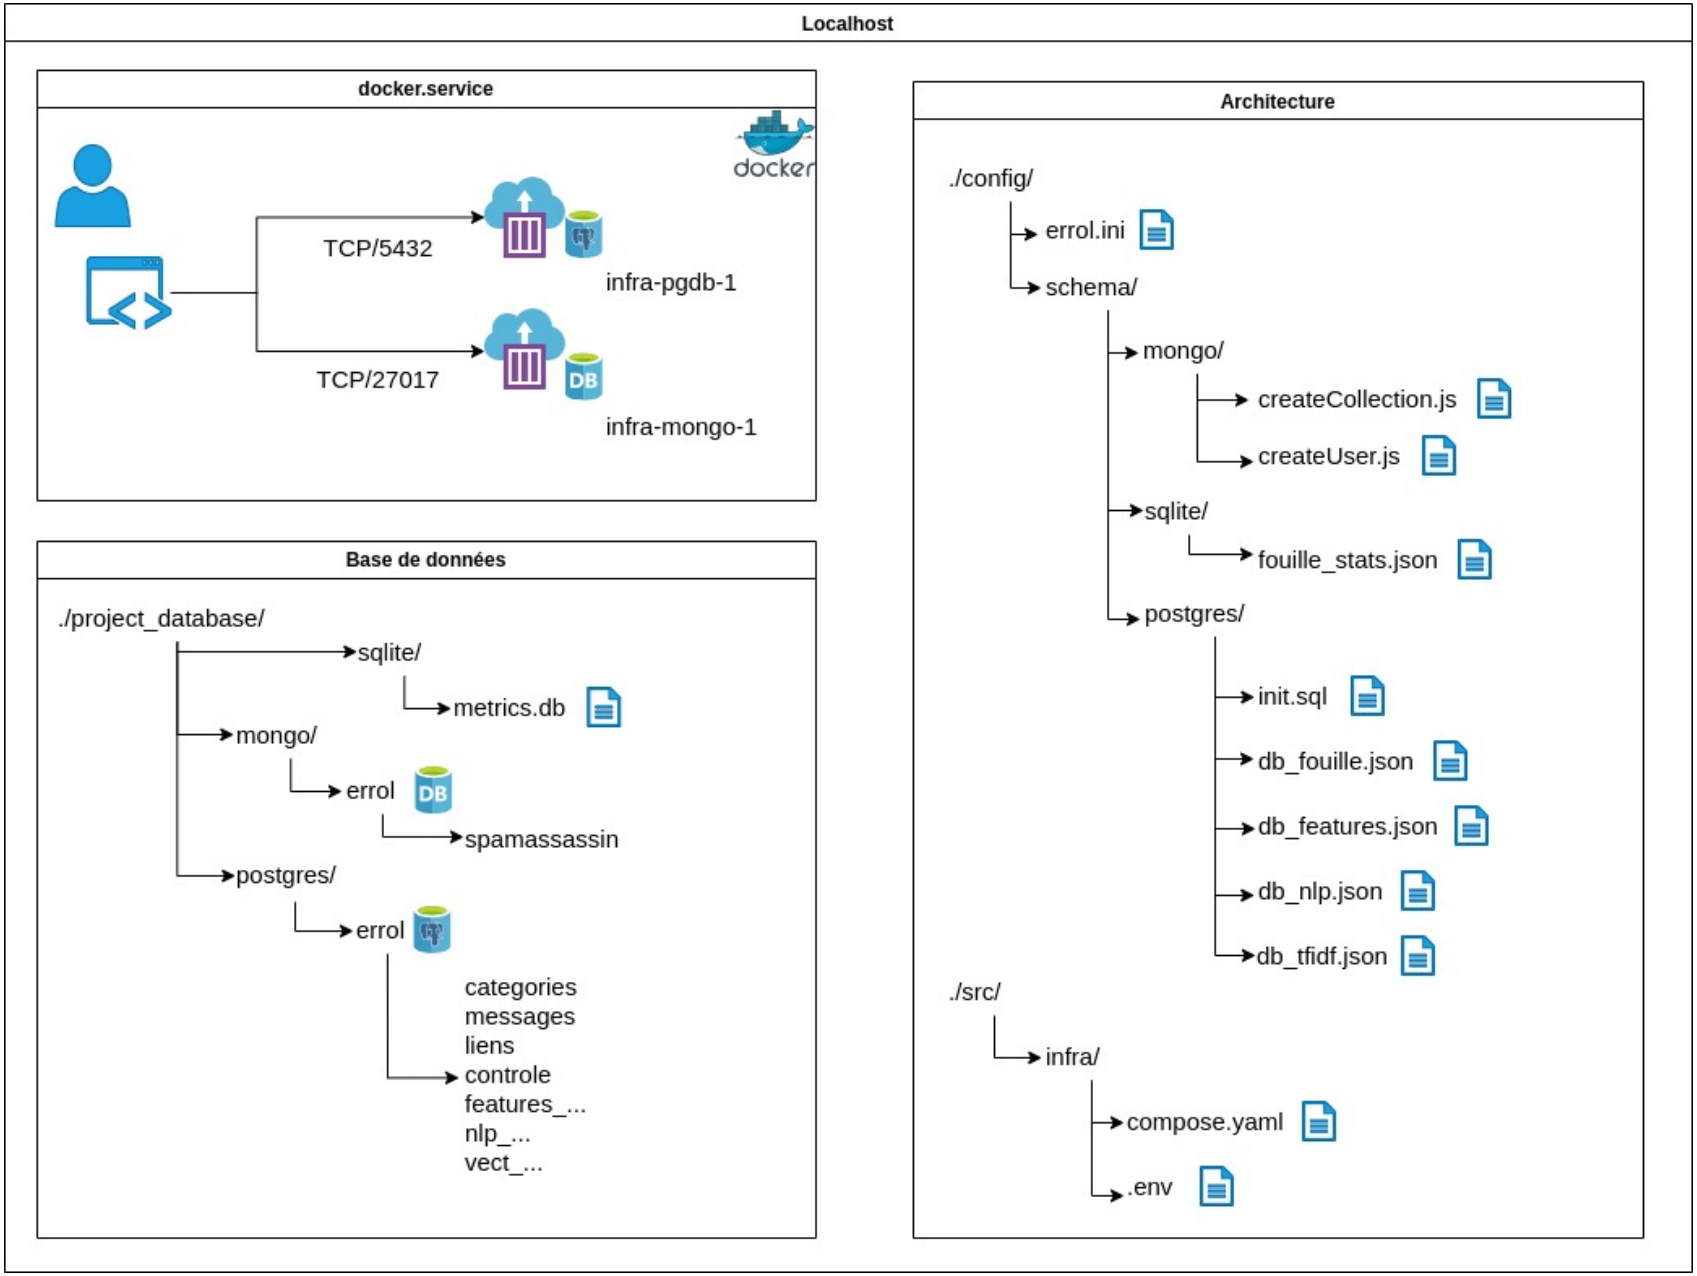
Localhost
docker.service
docker
TCP/5432
infra-pgdb-1
TCP/27017
DB
infra-mongo-1
Base de données
./project_database/
sqlite/
metrics.db
mongo/
errol
DB
spamassassin
postgres/
errol
categories
messages
liens
controle
features_...
nlp_...
vect_...
Architecture
./config/
errol.ini
schema/
mongo/
createCollection.js
createUser.js
sqlite/
fouille_stats.json
postgres/
init.sql
db_fouille.json
db_features.json
db_nlp.json
db_tfidf.json
./src/
infra/
compose.yaml
.env

Déroulé

L'éxécution des traitements se déroule en plusieurs phases :

- Importation des données et prétraitement (fouille.py)
- Recherche de caractéristiques (features.py)
- Traitement du langage naturel (nlp.py)
- Vectorisation (vecteurs.py)

Manquant

La partie sur l'utilisation des vecteurs dans un modèle d'apprentissage n'est pas traitée

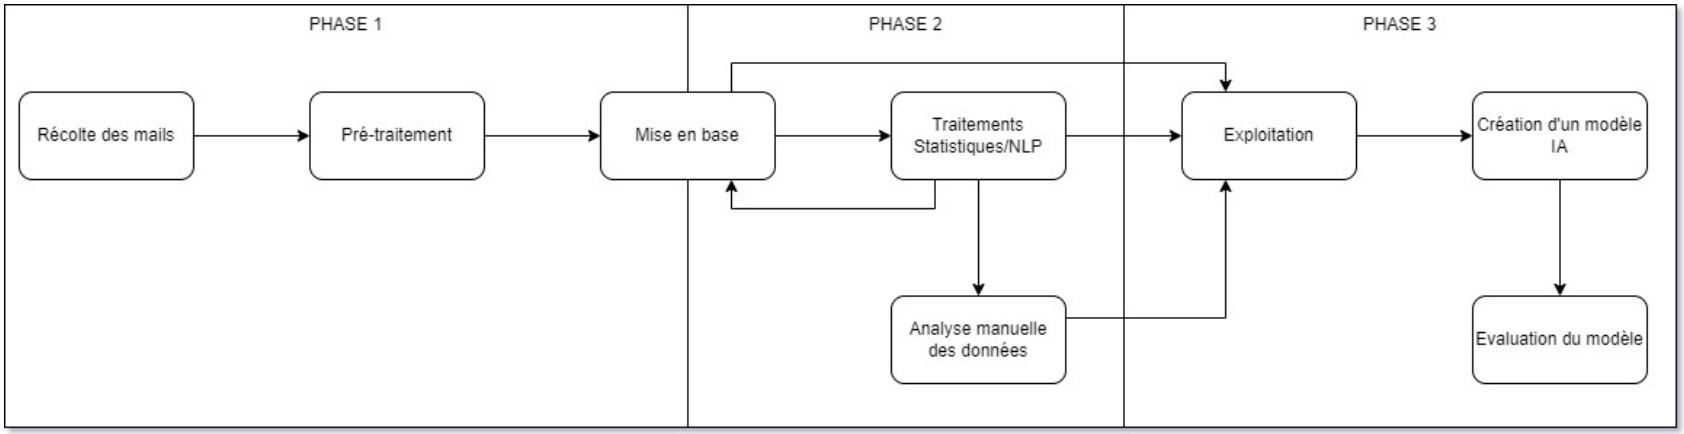
PHASE 1
PHASE 2
PHASE 3
Récolte des mails
Pré-traitement
Mise en base
Traitements Statistiques/NLP
Exploitation
Création d'un modèle IA
Analyse manuelle des données
Evaluation du modèle

Récupération des mails

Faute de sources, il n'a pas été possible de mettre en place une automatisation pour la récupération des mails. Il a été nécessaire de les récupérer manuellement dans d'autres projets du même type

Alternative

Une autre possibilité est de créer un site web dans lequel les utilisateurs auraient pu ajouter des nouveaux documents. Il aurait fallu prendre en compte la mise en place de cette architecture et les règlementations RGPD.

Corpus

Dataset de mail du projet SpamAssassin

- Anglais
- `https://spamassassin.apache.org/old/publiccorpus/`
- consulté le 27/01/2022
- environ 6000 fichiers email déjà trier en ham et spam

Dataset de mail de la compagnie Enron

- Anglais
- `https://www.kaggle.com/wcukierski/enron-email-dataset`
- consulté le 27/01/2022
- fichier CSV avec 33 millions de lignes (un mail par ligne) non trié
- Non utilisé ici

Etapes

Afin d'accélérer cette phase, chaque mail est traité dans un processus à par grace au *multiprocessing.Pool()*.

Importation

Les mails sont chargé en mémoire depuis les fichiers en utilisant la fonction *email.message_from_binary_file()*

Extraction

Un mail peut être multipart. On récupère récursivement uniquement les types text/plain, text/html, text/enriched. Les Headers et les autres types de MIME sont ignorés (audio, video, image...)

Etapes : Nettoyage

Cette étape permettre de nettoyer le texte de certains éléments non souhaités :

1. Suppression des balises html avec le module *BeautifulSoup* (bs4)
2. Suppression des balises enriched text avec le module *re*
3. Suppression des réponses avec le module *re*
4. Substitutions des adresses mail, url et numéro de téléphone avec le module *re*
5. Substitutions des prix et des nombres avec le module *re*
6. Suppression des ponctuations superflues avec le module *re*

Expressions régulières du nettoyage

- Capture des balises enriched text : `<.*>`
- Capture des réponses : `^>.*$`
- Capture mail :
  `[a-zA-Z0-9_.+-]+@[a-zA-Z0-9-]+\\.[a-zA-Z0-9-.]+`
- Capture url :
  `(http|ftp|https)?:\/\/([\w\-_]+(?:(?:\.[\w\-_]+)+))`
  `([\w\-\.,@?^=%&:/~\+#]*[\w\-\@?^=%&/~\+#])?`
- Capture téléphone1 : `\\(\\d{3}\\)\\d+-\\d+`
- Capture téléphone2 : `\\+\\d+([ .-]?\\d)+`
- Capture prix1 : `[$€£]( )?\\d+([.,]\\d+)?`
- Capture prix2 : `\\d+([.,]\\d+)?( )?[$€£]`
- Capture nombre : `\\d+`

Fouille - difficultés

Encodage

Certains encodages ne sont pas pris en charge par le module *email*. J'ai dû me limiter aux encodages suivants : ascii, Windows-1252, ISO-8859-1, utf-8.
J'utilise le module *chardet* pour faire la détection de l'encodage

Multiple charset

Les messages mails peuvent avoir plusieurs charset à l'intérieur du payload (*get_content_charset*). Les charset suivant m'ont posé des problèmes lors du traitement, j'ai écarté : unknown-8bit, default, default_charset, gb2312_charset, chinesebig5, big5.
Écarter ces charset permet d'enlever les messages écrits en turc, chinois ou japonais.

Fouille - difficultés

Langues

Le corpus contenant des mails dans d'autres langues. J'ai fait appel au module langdetect pour exclure les mails qui ne sont pas majoritairement en anglais.

Exemple de nettoyage texte brut

Brut

Message dedicated to be a sample to show how the process is clearing the text.
Begin reply : > He once said »> that it would be great End of reply. Substitutions : spamassassin-talk@example.sourceforge.net https ://www.inphonic.com/r.asp ?r=sourceforge1&refcode1=vs33 hello.foo.bar between $ 25 and 25,21 $
A number is : 2588,8 588 Phone type a : (359)1234-1000 Phone type b : +34 936 00 23 23 Ponctuation : —-## ..

Nettoyé

message dedicated to be a sample to show how the process is clearing the text. begin reply end of reply. substitutions MAIL URL URL between PRIX and PRIX a number is NOMBRE , NOMBRE NOMBRE phone type a TEL phone type b TEL ponctuation .

Nettoyage enriched text

Brut

<smaller>I'd like to swap with someone also using Simple DNS to take advantage of the trusted zone file transfer option.</smaller>

Nettoyé

I'd like to swap with someone also using Simple DNS to take advantage of the trusted zone file transfer option.

Nettoyage HTML brut


```
<!DOCTYPE html PUBLIC "-//W3C//DTD HTML 4.01 Transitional//EN">
<html>
<head>
  <title>Foobar</title>
</head>
<body>
I actually thought of this kind of active chat at AOL
bringing up ads based on what was being discussed and
other features
  <pre wrap="">On 10/2/02 12:00 PM, "Mr. FoRK"
  <a class="moz-txt-link-rfc2396E"href="mailto:fork_
  list@hotmail.com">&lt;fork_list@hotmail.com&gt;</a>
  wrote: Hello There, General Kenobi !?
<br>
</body>
</html>
```

Nettoyage HTML nettoyé


```
Foobar


I actually thought of this kind of active chat at AOL
bringing up ads based on what was being discussed and
other features
  On 10/2/02 12:00 PM, "Mr. FoRK"

  wrote: Hello There, General Kenobi !?
```

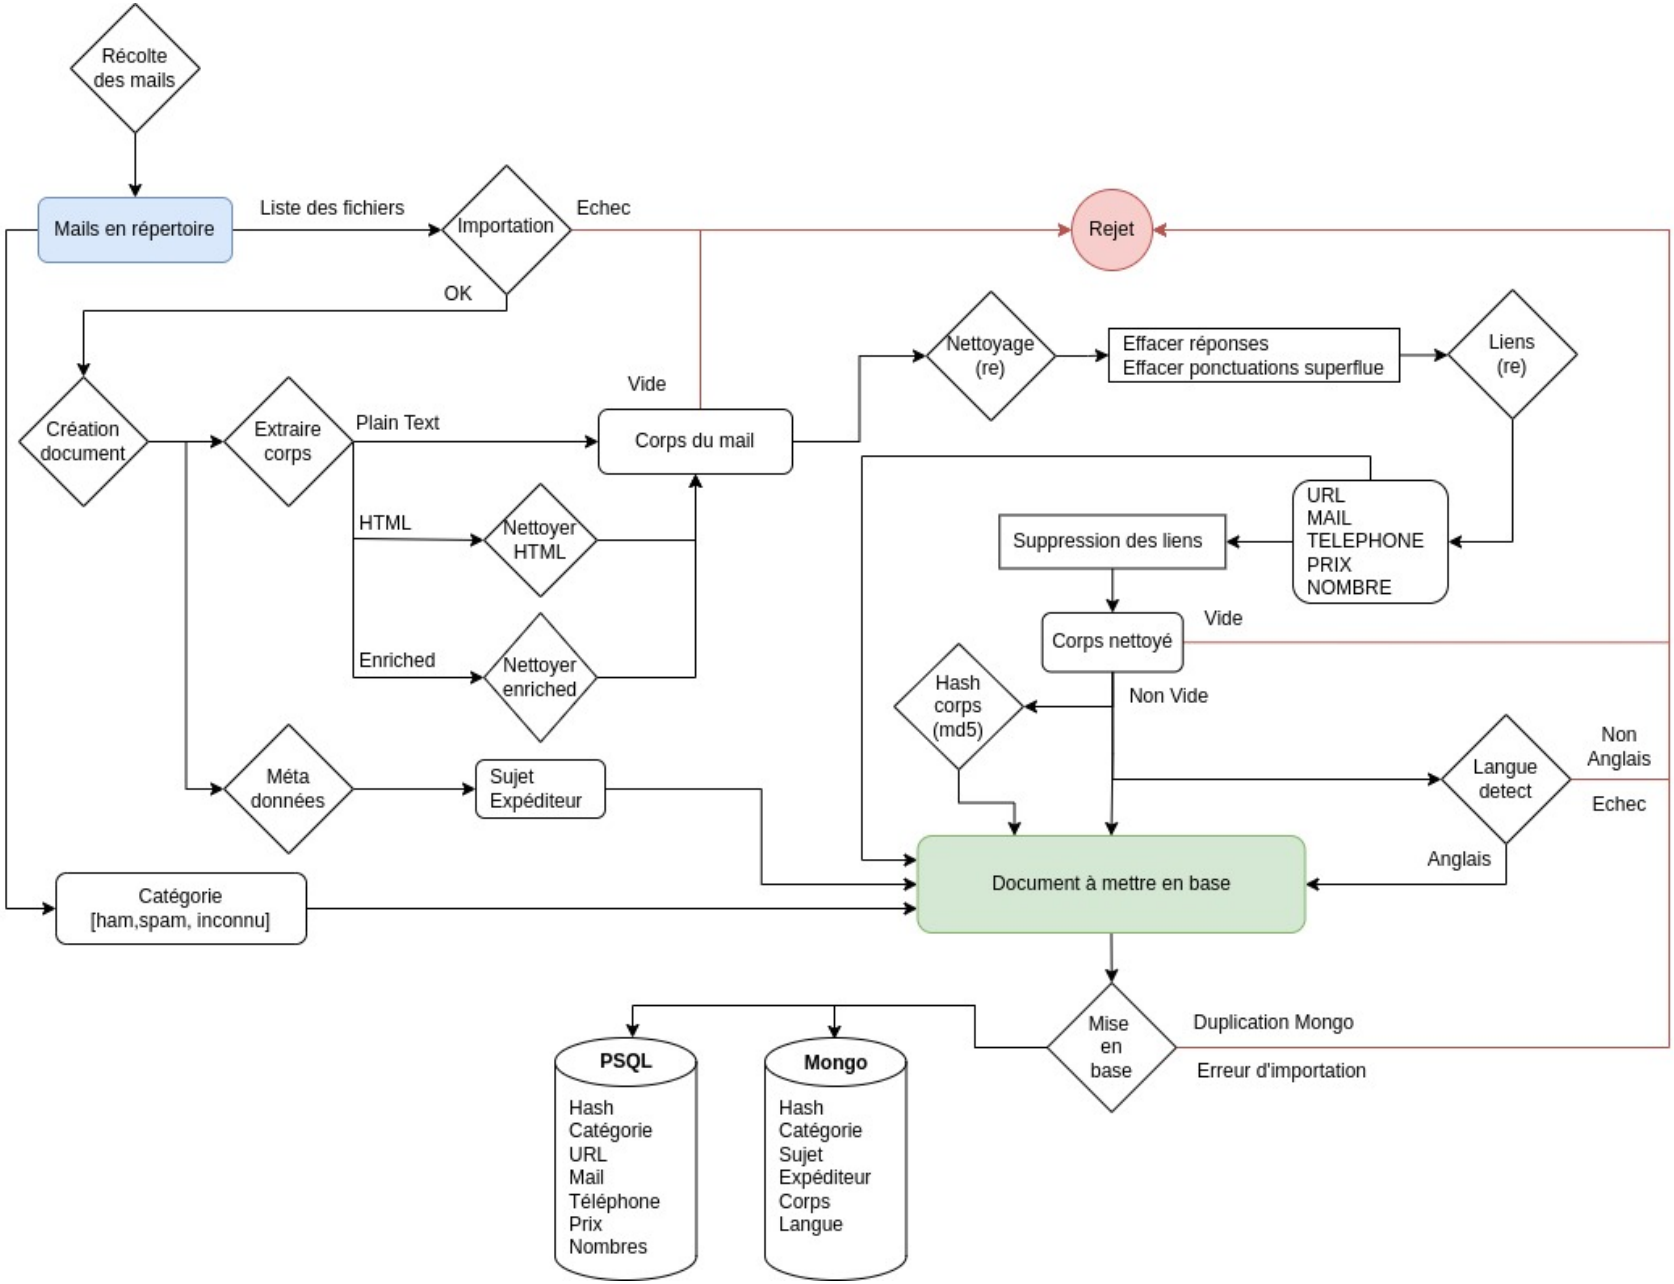
Récolte des mails
Mails en répertoire
Liste des fichiers
Importation
Echec
Rejet
OK
Création document
Extraire corps
Plain Text
Vide
Corps du mail
Nettoyage (re)
Effacer réponses
Effacer ponctuations superflue
Liens (re)
HTML
Nettoyer HTML
Enriched
Nettoyer enriched
URL
MAIL
TELEPHONE
PRIX
NOMBRE
Suppression des liens
Corps nettoyé
Vide
Non Vide
Hash corps (md5)
Méta données
Sujet Expéditeur
Langue detect
Non Anglais
Echec
Anglais
Catégorie [ham,spam, inconnu]
Document à mettre en base
Mise en base
Duplication Mongo
Erreur d'importation
PSQL
Hash
Catégorie
URL
Mail
Téléphone
Prix
Nombres
Mongo
Hash
Catégorie
Sujet
Expéditeur
Corps
Langue

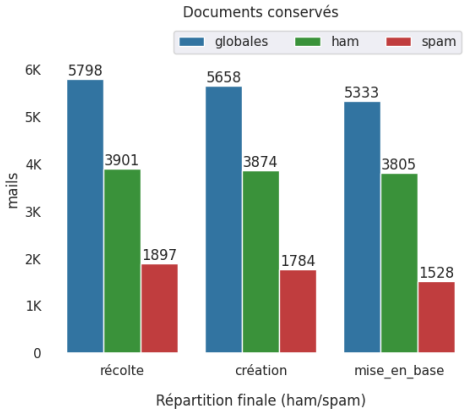

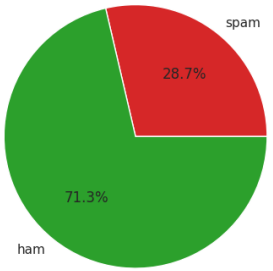

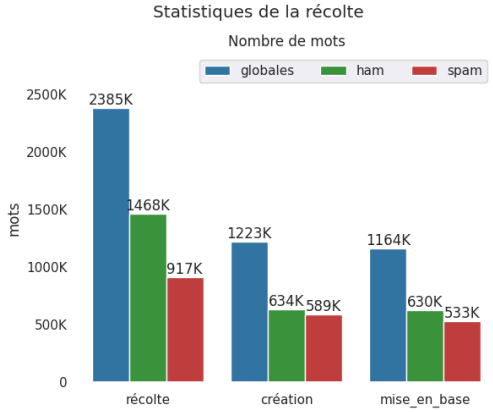

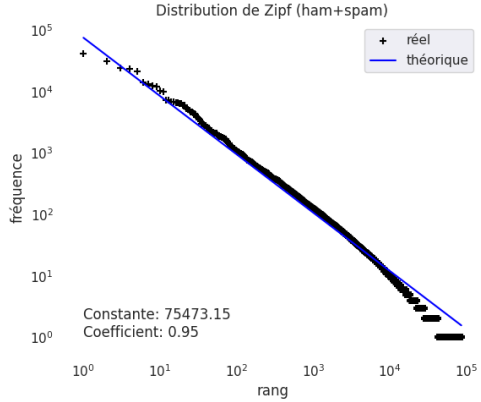

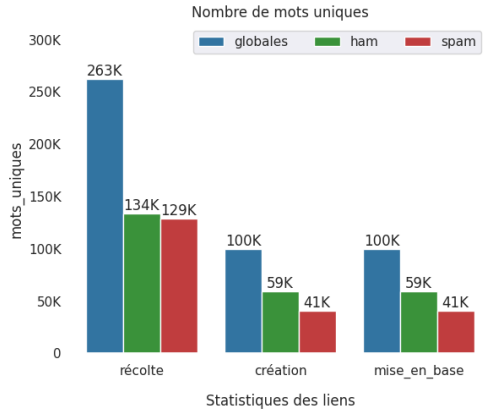

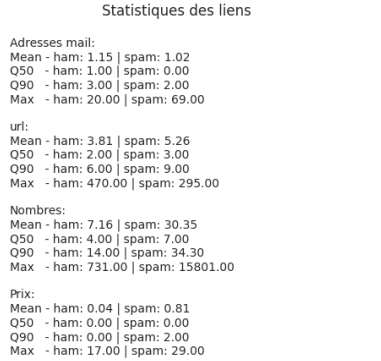

Les substitutions des adresses mails, des liens et des nombres, n'est pas très concluante.

Recherche de caractéristiques

Cette étape va se concentrer sur la forme plutôt que sur le fond. L'idée est de comprendre si certains éléments non textuels sont plus présent dans un type que dans un autre

Eléments recherchés

- Nombre de chars en majuscule et minuscule
- Nombre de mots en majuscule et capitalisé
- Nombre de ponctuations simple (point, virgule, exclamation, interrogation)
- Nombre d'espaces (espaces, tabulation, ligne vide)
- Nombre de lignes
- Données de la distribution de Zipf (constante, coefficient)
- Données de la rechercher d'Hapax (nombre, ratio dans le texte et dans la liste des mots uniques)

Exécution

Plusieurs fonctions de comptage sont executées itérativement sur chaque message. Toujours dans un souci de performance, le module multiprocessing est utilisé.
Le schéma si dessous montre les étapes de cette phase.

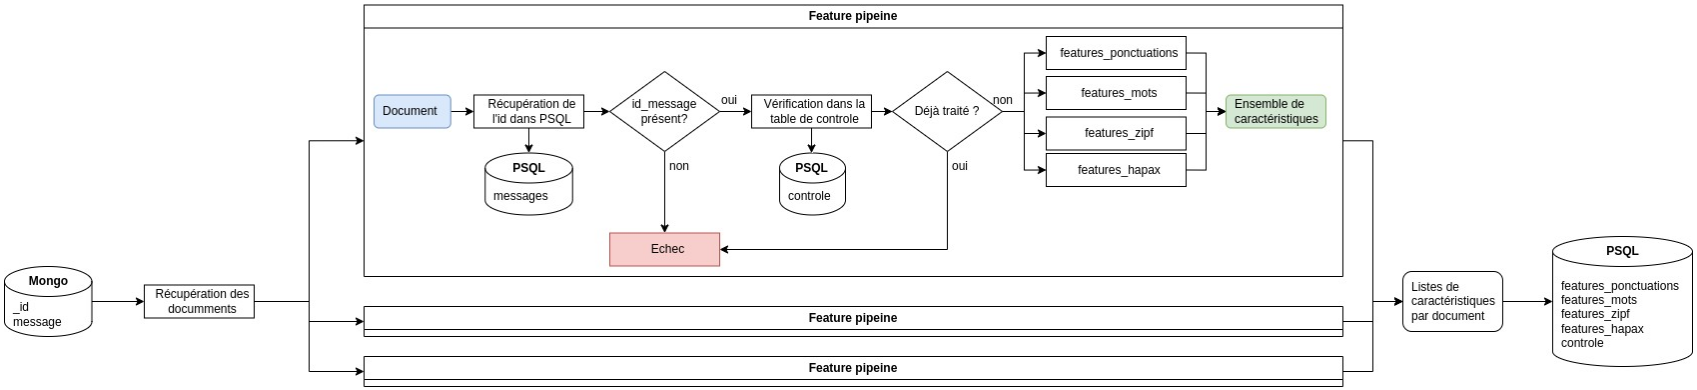

Methodes python utilisée

- str.count(...)
- len(re.findall(...))

Résultats

Sans représenter les détails du rapport, on peut lister les éléments suivants :

- Les spams utilisent plus de mots et de mots uniques
- Les mots complètement en majuscules sont très peu utilisés
- L'utilisation des ponctuations et des espaces est plus prononcé dans les spam

Caractéristiques retenues

- ratio-mots-uniques
- nombre hapax
- char-majuscule
- espaces

Covariance des caractéristiques

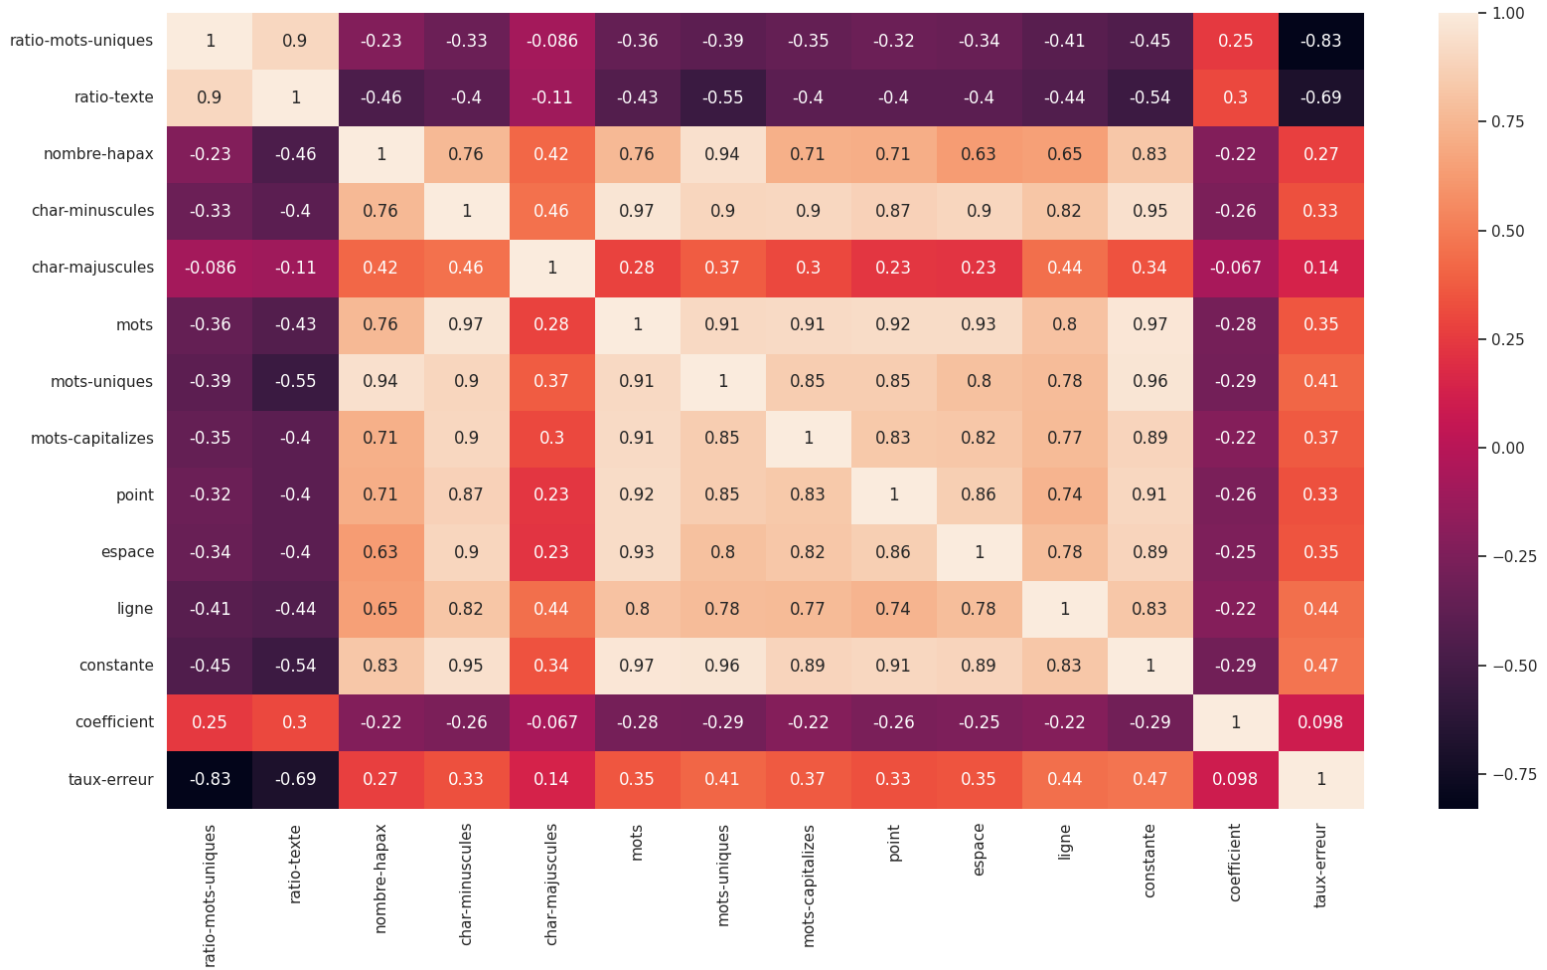

Traitement du langage

La technique choisie est la lemmatisation en utilisant le modèle neuronal de StandfordNLP (Stanza).

Etapes de la pipeline Stanza

1. Tokenisation
2. Multi-Word Token Expansion
3. Part Of Speech Tagging
4. Lemmatisation

Le comptage des mots est effectué par une fonction annexe (*zipf.freq_mot()*) L'utilisation du multiprocessing n'est pas possible ici du fait de l'utilisation de CUDA et la carte graphique.

Traitement du langage

Schéma d'éxecution :

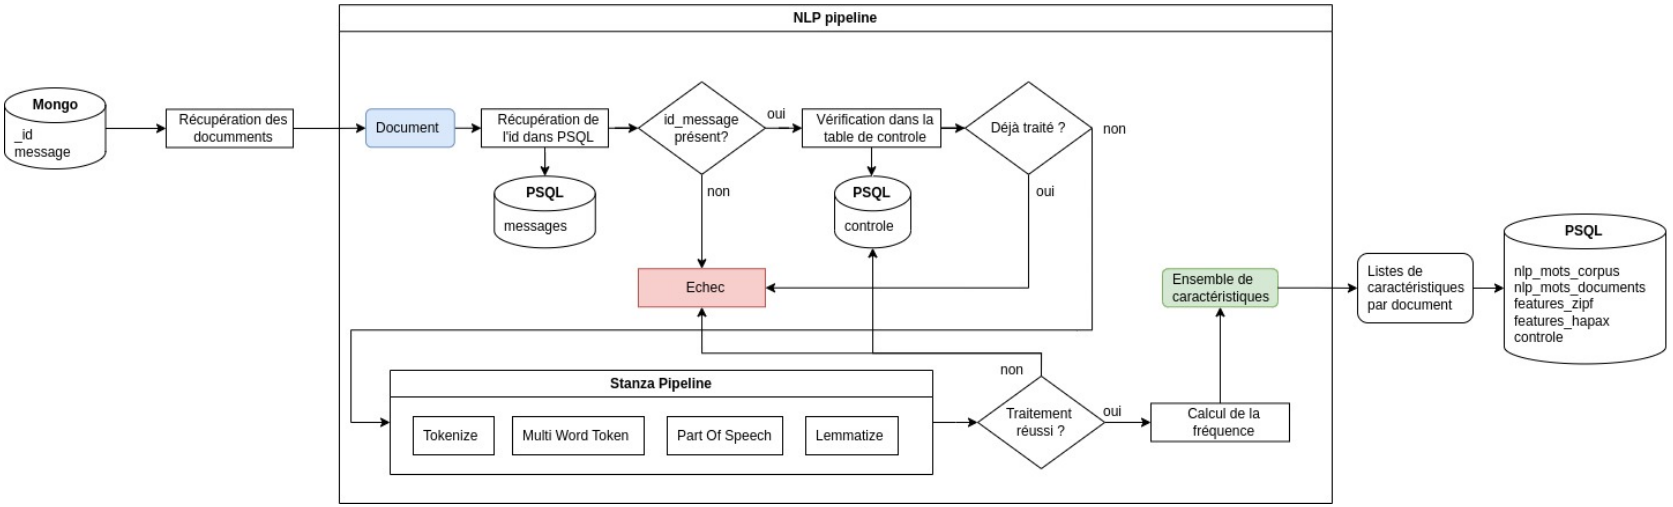

Tableau des résultats :

catégorie	mots	mots uniques
global	658524	39947
ham	355595	27787
spam	302929	19852

Vectorisation

En se basant sur une liste des mots les plus fréquents (ici 2940), il a été possible de transformer ces 5333 textes en données numériques. La méthode de vectorisation est celle du Term Frequency-Inverse Document Frequency (TFIDF).

Echantillons de mots du vecteur

list, get, use, email, one, make, free, time, person, send, new, information, would, work, say, receive, good, like, write, message, go, business, mailing, address, please, click, order, money, year, want, report, name, need, find, know, also, see, take, company, day, e-mail, remove, group, file, site, change, system, mail, program, look,...

Les mots sans connotations de sens ont été retiré du vecteur.

Schéma de la vectorisation

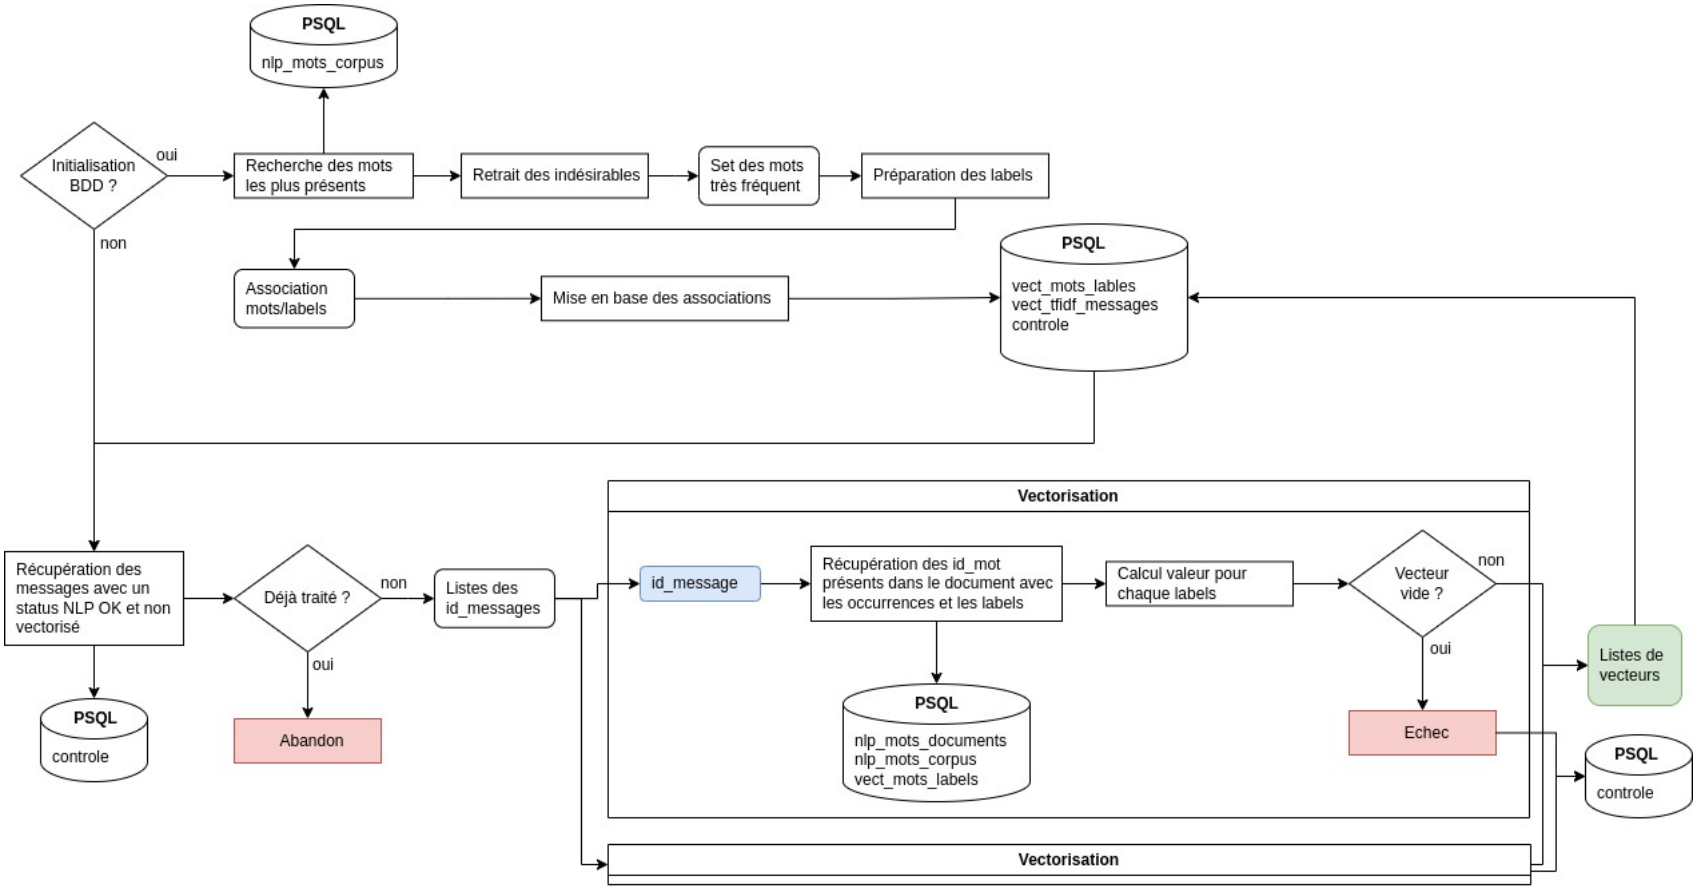

Il a été à nouveau possible d'utiliser le multiprocessing sur cette action.

Résultats

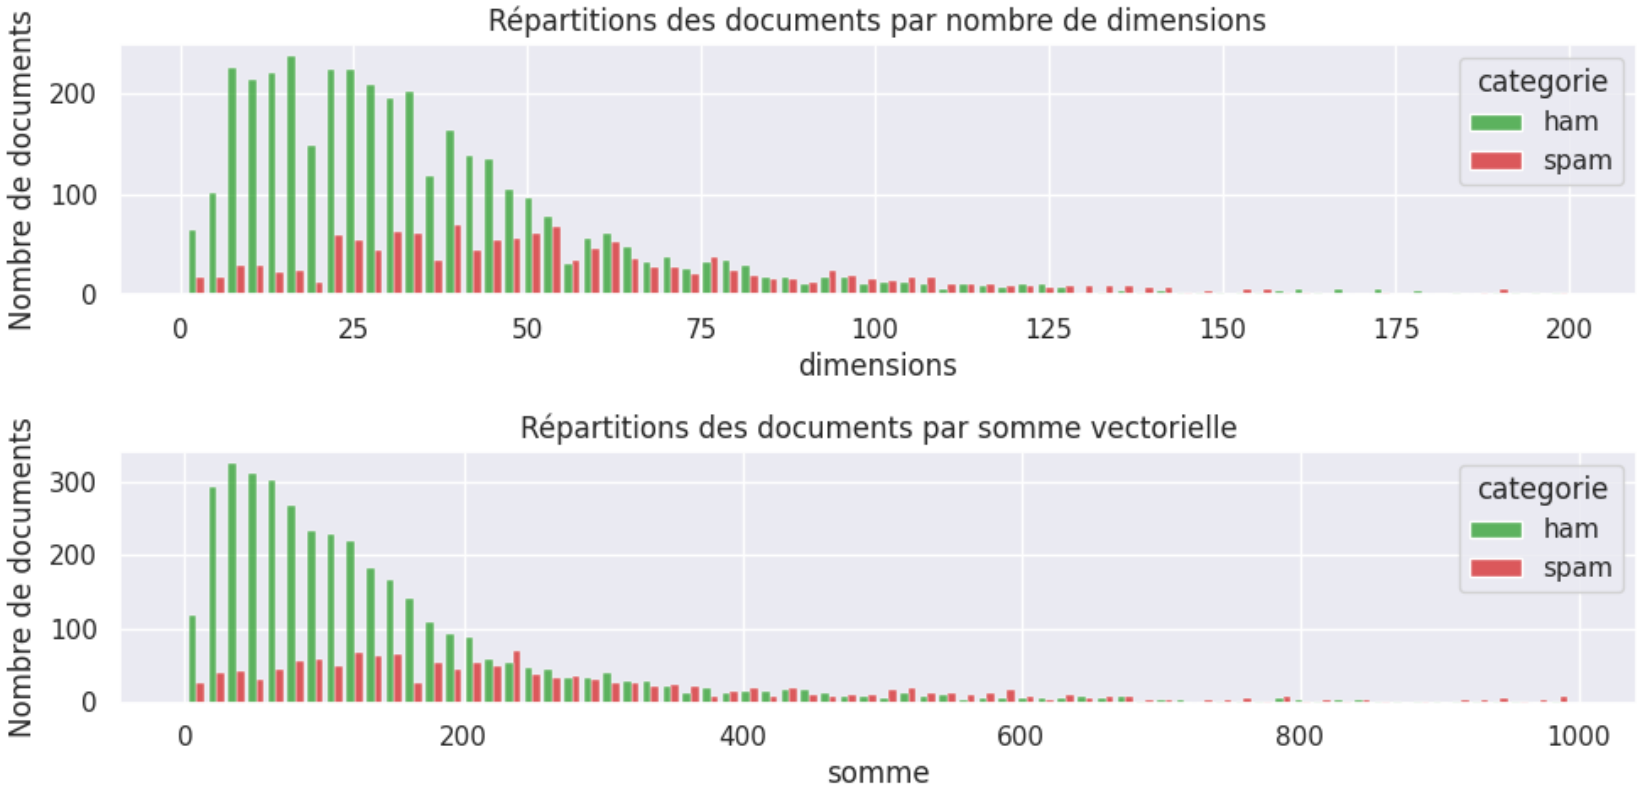
Répartitions des documents par nombre de dimensions
Nombre de documents
0
100
200
0
25
50
75
100
125
150
175
200
dimensions
categorie
ham
spam
Répartitions des documents par somme vectorielle
Nombre de documents
0
100
200
300
0
200
400
600
800
1000
somme
categorie
ham
spam

Résultats

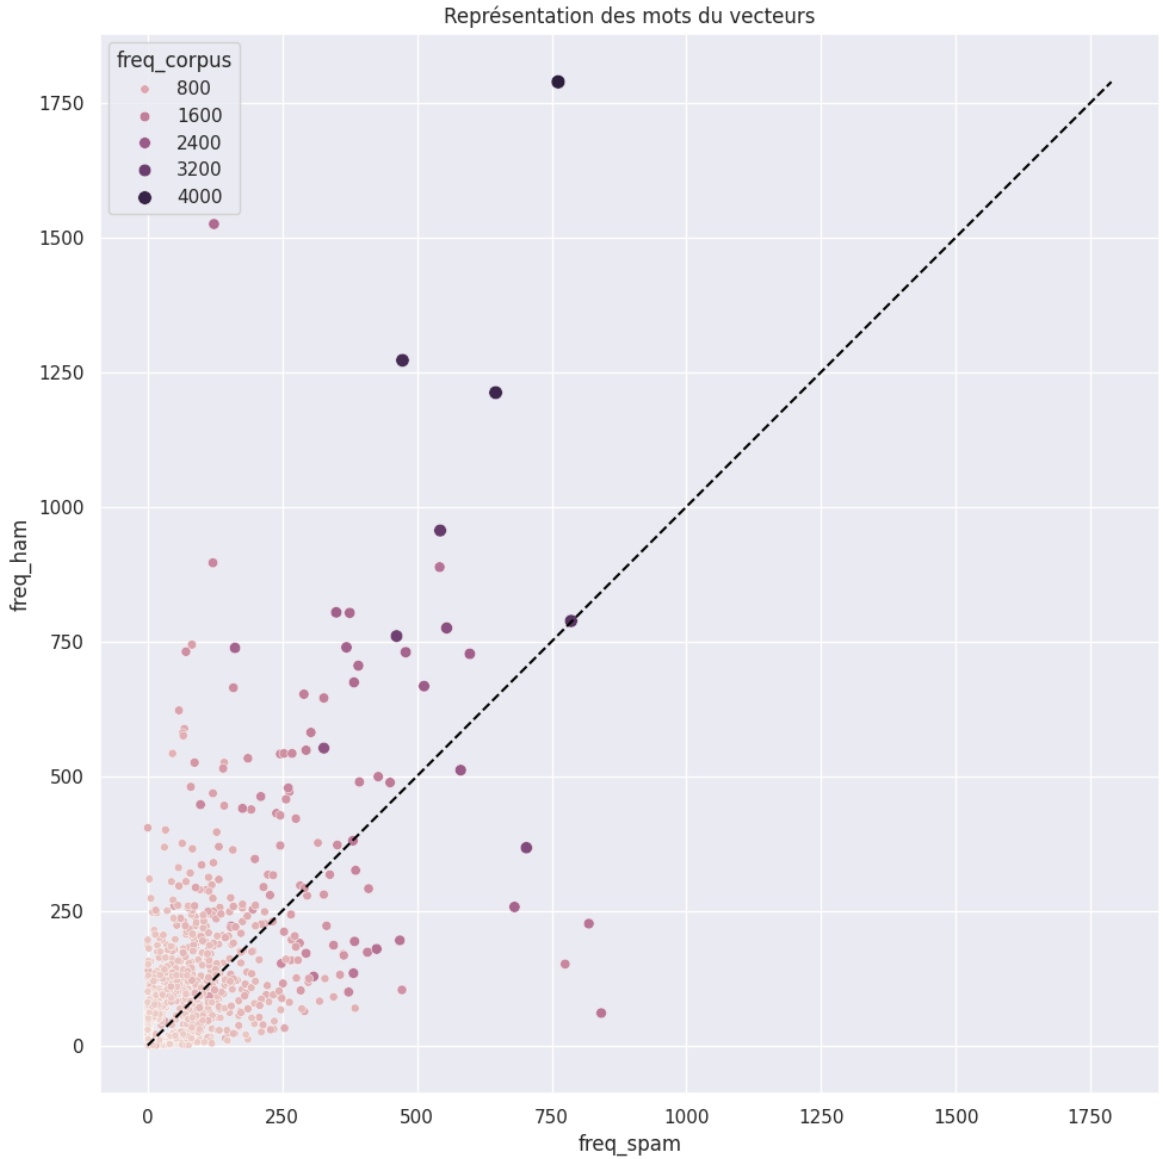
Représentation des mots du vecteurs
freq_corpus
800
1600
2400
3200
4000
freq_ham
freq_spam
0
250
500
750
1000
1250
1500
1750

Conclusion

Il a été possible d'effectuer tout un ensemble de traitement pour convertir des éléments textuels en données numériques. Ces opérations successives ont considérablement réduit le volume de données à traiter pour les modèles d'apprentissage.

Phase/Etape	documents	mots	mots uniques
Récolte	5798	2385120	262614
Transformation	5658	1222793	99772
Sauvegarde	5333	1163550	99772
Traitement du langage	5333	658524	39947
Vectorisation	5333	453068	2942

Et ensuite

Modélisation

Les étapes de modélisation et d'apprentissage ne sont pas présentes ici. Lors de la version précédente du projet, j'avais obtenu des résultats encourageant avec Random Tree Forest ou Support Vector Machine.

Amélioration

L'analyse actuelle n'est pas très poussée pour la recherche de données abérrantes qui pourrait corrompre les modèles futurs.

Merci pour votre attention